FACULDADE DE TECNOLOGIA DE FRANCA – FATEC FRANCA
Disciplina: Machine Learning

Gabriel Pessoni
Lívia Portela Ferreira

PREVISÃO DE VENDAS COM MODELOS DE REGRESSÃO

Pré-processamento e avaliação sobre a base *Store Sales*

Franca
2026

SUMÁRIO

1 INTRODUÇÃO 3
2 OBJETIVOS 3
2.1 Objetivo geral 3
2.2 Objetivos específicos 3
3 BASE DE DADOS 3
3.1 Origem e estrutura 3
3.2 Recorte utilizado 4
4 PRÉ-PROCESSAMENTO 4
4.1 Remoção do período anterior à abertura das lojas 4
4.2 Recorte, duplicados e valores ausentes 5
4.3 Integração das tabelas 5
4.4 Valores extremos 5
4.5 Agrupamento de onpromotion 5
4.6 Atributos de data e codificação 5
5 SELEÇÃO DE ATRIBUTOS E NORMALIZAÇÃO 6
6 ALGORITMOS DE REGRESSÃO 6
6.1 Regressão Linear 6
6.2 Random Forest 7
6.3 Métricas de avaliação 7
7 RESULTADOS E DISCUSSÃO 7
8 CONSIDERAÇÕES FINAIS 8

1 INTRODUÇÃO

Prever a demanda é uma das tarefas mais valiosas na gestão de um varejo: a quantidade de produtos em estoque depende diretamente de quanto se espera vender. Estoque a menos gera ruptura e perda de vendas; estoque a mais imobiliza capital e aumenta o risco de perdas. Modelos de aprendizado de máquina permitem estimar essa demanda a partir do histórico de vendas e de variáveis que a influenciam, como promoções, calendário e características das lojas.

Este documento descreve o trabalho desenvolvido no notebook *Previsao_Vendas.ipynb*, que prevê a quantidade vendida por dia, loja e família de produtos a partir da base pública *Store Sales – Time Series Forecasting*, do entendimento da base e do pré-processamento até a comparação de dois algoritmos de regressão e de dois métodos de seleção de atributos.

2 OBJETIVOS

2.1 Objetivo geral

Construir um fluxo de aprendizado de máquina que, a partir de dados históricos de vendas de uma rede varejista, estime o volume vendido por dia, loja e família de produtos.

2.2 Objetivos específicos

Os objetivos específicos são: (a) compreender a estrutura da base e identificar problemas de qualidade; (b) preparar os dados por meio de limpeza, integração de tabelas e criação de atributos; (c) reduzir o número de atributos com dois métodos de seleção (*SelectKBest* e RFE); (d) treinar e comparar a Regressão Linear e a *Random Forest*; e (e) avaliar os modelos com métricas de erro e discutir as limitações do experimento.

3 BASE DE DADOS

3.1 Origem e estrutura

A base *Store Sales – Time Series Forecasting* foi disponibilizada na plataforma Kaggle (COOK et al., 2021) e reúne dados de lojas da rede varejista equatoriana Corporación Favorita. Ela é formada por seis arquivos CSV, resumidos na Tabela 1. O arquivo central é o *train.csv*, com 3.000.888 registros diários de 54 lojas e 33 famílias de produtos, de 1º de janeiro de 2013 a 15 de agosto de 2017. Cada linha informa a data, a loja (*store_nbr*), a família de produtos (*family*), o total vendido no dia (*sales*) e quantos itens da família estavam em promoção (*onpromotion*). A coluna *sales* é a variável que se deseja prever.

Tabela 1 – Arquivos que compõem a base de dados

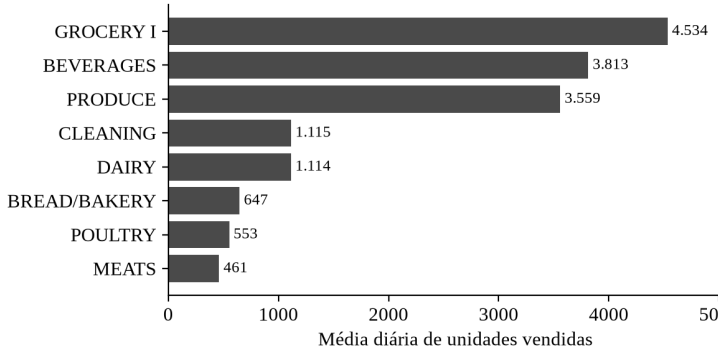
Arquivo	Conteúdo	Registros	Uso no notebook
train.csv	Vendas por data, loja e família	3.000.888	Base principal
test.csv	Dias seguintes (16/08 a 31/08/2017), sem a coluna sales	28.512	Não utilizado nesta versão
stores.csv	Cidade, estado, tipo (A a E) e agrupamento (*cluster*) de cada loja	54	Tipo e *cluster*
oil.csv	Preço diário do petróleo (*dcoilwtico*), importante para a economia do país	1.218	Preço do petróleo
holidays_events.csv	Feriados e eventos	350	Não utilizado
transactions.csv	Número de transações por loja e dia	83.488	Não utilizado

Fonte: adaptado de Cook et al. (2021).

3.2 Recorte utilizado

Como a base completa é grande, o notebook trabalha com um recorte: as lojas de número 1 a 5 e os registros a partir de 1º de janeiro de 2016, o que resulta em 97.680 linhas. As cinco lojas pertencem ao tipo D; quatro ficam em Quito e uma em Santo Domingo. Nesse recorte, a média de vendas é de 532,8 unidades por registro, com mediana de apenas 37 e máximo de 124.717, e 10,5% dos registros têm venda igual a zero. A distribuição é assimétrica, e poucas famílias concentram o volume. A Figura 1 mostra as oito famílias com maior média diária.

Figura 1 – Famílias de produtos com maior média diária de vendas (lojas 1 a 5, a partir de 2016)



Fonte: elaborado pelos autores (2026), com dados de Cook et al. (2021).

4 PRÉ-PROCESSAMENTO

4.1 Remoção do período anterior à abertura das lojas

Em 53 das 54 lojas há registros com venda zero antes da primeira venda real. Esse zero não indica falta de demanda: a loja ainda não existia. Mantê-lo ensinaria ao modelo uma relação falsa. Para cada loja, o notebook calcula a data do primeiro dia com vendas maiores

que zero e descarta as linhas anteriores. Na base completa, isso remove 222.057 dos 3.000.888 registros, todos com venda zero. As lojas 20, 21, 22, 29, 42, 52 e 53, por exemplo, só passaram a vender entre 2014 e 2017. Nas lojas 1 a 5, que operam desde 2013, a etapa não altera o recorte; ela garante o fluxo correto se mais lojas forem incluídas.

4.2 Recorte, duplicados e valores ausentes

Feito o recorte descrito na seção 3.2, o notebook verifica linhas duplicadas e campos essenciais ausentes (data, loja, família e vendas). Nenhum dos dois problemas foi encontrado; atributos ausentes seriam preenchidos pela mediana (numéricos) ou por uma categoria explícita (texto).

4.3 Integração das tabelas

A tabela de vendas é enriquecida por junções. De *stores.csv* entram o tipo e o *cluster* da loja. De *oil.csv* entra o preço do petróleo, que tem 43 valores vazios e cotações apenas em dias úteis. Para evitar lacunas, o petróleo é expandido para todos os dias do calendário e os dias sem cotação recebem o último valor conhecido; se faltar no início da série, usa-se o primeiro valor disponível. Sem esse cuidado, as junções deixavam valores vazios.

4.4 Valores extremos

Pelo método do intervalo interquartil, 14.016 registros (cerca de 14%) ficam fora do intervalo de −484,31 a 823,19. Como são picos de grandes famílias, e não erros de registro, foram mantidos: removê-los esconderia os dias de maior demanda.

4.5 Agrupamento de *onpromotion*

A quantidade de itens em promoção assume 216 valores distintos. Para reduzir essa cardinalidade e capturar a intensidade da promoção, ela foi dividida em quatro faixas ordenadas: nenhum item (0), de 1 a 3 itens (1), de 4 a 16 (2) e mais de 16 itens (3). Os registros ficam distribuídos em 57.484, 17.301, 13.257 e 9.638, respectivamente.

4.6 Atributos de data e codificação

A data original é um texto e não pode ser usada diretamente. Dela são extraídos o dia da semana, o dia do mês e o mês, que capturam padrões como o aumento de vendas aos fins de semana. As colunas *id* e *date* são removidas, por serem identificador e informação já aproveitada. As variáveis categóricas (família e tipo da loja) são convertidas em colunas de 0 e 1 (*one-hot encoding*), pois os algoritmos operam apenas sobre números. Ao final, a tabela tem 97.680 linhas e 41 atributos, além da variável-alvo. Como as cinco lojas são do tipo D, a coluna de tipo é constante e não contribui para o modelo.

5 SELEÇÃO DE ATRIBUTOS E NORMALIZAÇÃO

Primeiro, os dados são divididos aleatoriamente em 70% para treino (68.376 linhas) e 30% para teste (29.304), com semente fixa (*random_state* = 1) para que o resultado seja reprodutível. A seleção de atributos usa apenas o treino, para que nenhuma informação do teste influencie a escolha. Dos 41 atributos, mantêm-se dez por dois métodos distintos, o que permite comparar o efeito da escolha (GUYON; ELISSEEFF, 2003).

O *SelectKBest* é um método de filtro: pontua cada atributo isoladamente pelo teste F de regressão, que mede a relação linear com a venda, e retém os dez melhores (PEDREGOSA et al., 2011). Ele escolheu a promoção e nove famílias de produtos (bebidas, livros, limpeza, laticínios, mercearia I, ferragens, eletrodomésticos, hortifrúti e material escolar).

O RFE (*Recursive Feature Elimination*) é um método *wrapper*: treina um modelo, descarta o atributo menos importante e repete o processo até restarem dez (GUYON et al., 2002). Aqui o modelo-base é uma regressão linear com padronização. Ele escolheu o número da loja, a promoção, o *cluster* e sete famílias (bebidas, limpeza, laticínios, mercearia I, utensílios II, hortifrúti e frutos do mar).

A **normalização** (padronização pela média e pelo desvio-padrão) é aplicada somente à Regressão Linear, por meio de um *pipeline* que aprende os parâmetros no treino. Atributos em escalas diferentes, como o número da loja e as colunas de 0 e 1, tornariam os coeficientes incomparáveis. A *Random Forest* não precisa dessa etapa, pois suas decisões dependem apenas da ordem dos valores.

6 ALGORITMOS DE REGRESSÃO

A variável a prever é numérica e contínua, o que caracteriza um problema de regressão (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). Foram escolhidos dois algoritmos de naturezas opostas: um modelo simples e interpretável e um modelo flexível capaz de capturar relações complexas. Ambos foram implementados com a biblioteca *scikit-learn* (PEDREGOSA et al., 2011) e os dados foram manipulados com *pandas* (MCKINNEY, 2010).

6.1 Regressão Linear

A Regressão Linear supõe que a venda é uma soma ponderada dos atributos:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_p x_p + \varepsilon \quad (1)$$

em que y é a venda, x_j são os atributos, β_j são os coeficientes estimados pelo método dos mínimos quadrados e ε é o erro. Sua principal vantagem é a interpretabilidade: cada coeficiente mostra o quanto a venda muda quando o atributo aumenta uma unidade (aqui, um desvio-padrão, pois os dados são padronizados). No modelo com RFE, o intercepto é de 535,16 e os maiores coeficientes são os das famílias mercearia I (+705,6), bebidas (+573,4) e hortifrúti (+556,3), coerentes com a Figura 1. Sua limitação é supor relações lineares e

aditivas.

6.2 Random Forest

A *Random Forest* combina muitas árvores de decisão treinadas em amostras diferentes dos dados e com sorteio de atributos a cada divisão; a previsão final é a média das previsões das árvores (BREIMAN, 2001). Esse método captura relações não lineares e interações (como o efeito da promoção diferir entre famílias ou lojas) sem exigir normalização. O notebook usa 50 árvores, para manter o treino rápido, e semente fixa. Em contrapartida, é menos interpretável que a regressão.

6.3 Métricas de avaliação

Os modelos são avaliados no conjunto de teste, que não participou do treino nem da seleção de atributos. O coeficiente de determinação (R^2) indica a fração da variação das vendas explicada pelo modelo, sendo 1 o valor ideal. O erro absoluto médio (MAE) é a média dos erros em unidades vendidas, e a raiz do erro quadrático médio (RMSE) penaliza mais os erros grandes.

7 RESULTADOS E DISCUSSÃO

A Tabela 2 reúne o desempenho das quatro combinações no conjunto de teste (29.304 registros).

Tabela 2 – Desempenho dos modelos no conjunto de teste

Seleção	Algoritmo	R^2	MAE	RMSE
SelectKBest	Regressão Linear	0,6270	311,80	857,40
SelectKBest	Random Forest	0,6279	312,22	856,27
RFE	Regressão Linear	0,6337	345,62	849,67
RFE	Random Forest	0,9156	172,82	407,87

Fonte: elaborado pelos autores (2026). MAE e RMSE em unidades vendidas.

Os resultados mostram três pontos, e o RMSE bem maior que o MAE em todos os modelos indica erros concentrados em poucos registros de alto volume. Primeiro, a combinação *Random Forest* com RFE foi claramente a melhor: explica 91,6% da variação das vendas e tem erro médio de 172,8 unidades, contra R^2 próximo de 0,63 nas demais. Segundo, com o *SelectKBest* os dois algoritmos ficaram praticamente empatados (0,6270 e 0,6279). Os dez atributos escolhidos são a promoção e famílias de produtos, que não distinguem uma loja da outra nem um dia do outro; sem essas informações, nem um modelo flexível consegue ir além. Terceiro, o RFE incluiu o número da loja e o *cluster*, e foi com eles que a *Random Forest* pôde aprender o nível de venda de cada loja e dar o salto de desempenho. Já a Regressão Linear quase não melhorou com o RFE, o que sugere que a relação entre esses atributos e a venda não é linear.

Para dimensionar o efeito da seleção, treinamos também a *Random Forest* com os 41 atributos, o que deu R^2 de 0,9518. Assim, reduzir a dez atributos pelo RFE custou cerca de 0,036 de R^2; o *SelectKBest* descartou informação decisiva. A escolha do método de seleção pesou mais do que a escolha do algoritmo.

8 CONSIDERAÇÕES FINAIS

O trabalho percorreu o caminho completo de um projeto de regressão: entendimento da base, limpeza, integração, criação de atributos, seleção, treinamento e avaliação. O pré-processamento foi decisivo para a qualidade dos dados, e a *Random Forest* com atributos escolhidos pelo RFE entregou o melhor resultado (R^2 de 0,9156).

Há limitações que precisam ficar claras. A divisão entre treino e teste é aleatória, e não cronológica: dias vizinhos aparecem nos dois conjuntos, o que tende a tornar o R^2 mais otimista do que seria ao prever dias realmente futuros. O modelo não usa vendas passadas (*lags*), feriados nem o número de transações, que são fontes naturais de informação em previsão de demanda. O recorte cobre apenas cinco lojas, todas do mesmo tipo, e o arquivo *test.csv* não é usado nesta versão. Como trabalhos futuros, sugerem-se a divisão por data, a inclusão desses atributos e o uso de todas as lojas.

REFERÊNCIAS

BREIMAN, Leo. Random forests. **Machine Learning**, v. 45, n. 1, p. 5-32, 2001.

COOK, Alexis; DANB; INVERSION; HOLBROOK, Ryan. **Store Sales – Time Series Forecasting**. Kaggle, 2021. Disponível em: https://www.kaggle.com/competitions/store-sales-time-series-forecasting. Acesso em: out. 2026.

GUYON, Isabelle; ELISSEEFF, André. An introduction to variable and feature selection. **Journal of Machine Learning Research**, v. 3, p. 1157-1182, 2003.

GUYON, Isabelle; WESTON, Jason; BARNHILL, Stephen; VAPNIK, Vladimir. Gene selection for cancer classification using support vector machines. **Machine Learning**, v. 46, p. 389-422, 2002.

HASTIE, Trevor; TIBSHIRANI, Robert; FRIEDMAN, Jerome. **The elements of statistical learning**: data mining, inference, and prediction. 2. ed. New York: Springer, 2009.

MCKINNEY, Wes. Data structures for statistical computing in Python. In: PYTHON IN SCIENCE CONFERENCE, 9., 2010, Austin. **Proceedings** [...]. Austin: SciPy, 2010. p. 56-61.

PEDREGOSA, Fabian *et al*. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825-2830, 2011.